Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа №3
по дисциплине
«Методы машинного обучения»
на тему

«Разведочный анализ данных. Исследование и визуализация данных»

Выполнил:
студент группы ИУ5И-21М
Ван Чжэн

Москва — 2024 г.

1. Цель лабораторной работы

изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.

2. Задание

1. Выбрать один или несколько наборов данных (датасетов) для решения следующих задач. Каждая задача может быть решена на отдельном датасете, или несколько задач могут быть решены на одном датасете. Просьба не использовать датасет, на котором данная задача решалась в лекции.
2. Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:
   i. масштабирование признаков (не менее чем тремя способами);
   ii. обработку выбросов для числовых признаков (по одному способу для удаления выбросов и для замены выбросов);
   iii. обработку по крайней мере одного нестандартного признака (который не является числовым или категориальным);
   iv. отбор признаков:
      - один метод из группы методов фильтрации (filter methods);
      - один метод из группы методов обертывания (wrapper methods);
      - один метод из группы методов вложений (embedded methods)

3. Ход выполнения работы

3.1 Масштабирование признаков

Я выбираю набор данных «Apple Stock Price».

```
dataset = pd.read_csv('/content/Apple Dataset.csv')
dataset.head()
```

	Date	Open	High	Low	Close	Adj Close	Volume
0	1980-12-12	0.128348	0.128906	0.128348	0.128348	0.099058	469033600
1	1980-12-15	0.122210	0.122210	0.121652	0.121652	0.093890	175884800
2	1980-12-16	0.113281	0.113281	0.112723	0.112723	0.086999	105728000
3	1980-12-17	0.115513	0.116071	0.115513	0.115513	0.089152	86441600
4	1980-12-18	0.118862	0.119420	0.118862	0.118862	0.091737	73449600

后续步骤： 查看推荐的图表

Метод Z-оценки

```
def arr_df(a):
        df = pd.DataFrame(a, columns=X_train.columns)
        return df
scaler1 = StandardScaler()
scaled_X_1 = arr_df(scaler1.fit_transform(X_train))
scaled_X_1
```

	Open	High	Low	Adj Close	Volume
0	0.337430	0.335349	0.337966	0.298647	-0.660500
1	-0.467443	-0.467577	-0.467500	-0.456911	-0.183579
2	-0.472395	-0.472309	-0.472249	-0.460149	0.157891
3	-0.475215	-0.475194	-0.475021	-0.462833	-0.478233
4	0.272519	0.273723	0.279046	0.249404	-0.559373
...	...	...	...	...	...
8210	-0.402232	-0.402714	-0.402379	-0.400381	2.964490
8211	-0.342069	-0.342369	-0.340772	-0.349099	0.012463
8212	-0.468634	-0.468623	-0.468616	-0.457153	-0.179364
8213	-0.469251	-0.469341	-0.469073	-0.457978	-0.589765
8214	-0.474600	-0.474461	-0.474501	-0.462151	1.691657

8215 rows x 5 columns

```
def data_visualize(columns, df1, df2, label1, label2):
    fig, (ax1, ax2) = plt.subplots(ncols=2, figsize=(12, 5))
    ax1.set_title(label1)
    sns.kdeplot(data=df1[columns], ax=ax1)
    ax2.set_title(label2)
    sns.kdeplot(data=df2[columns], ax=ax2)
    plt.show()

data_visualize(X_train.columns, X_train, scaled_X_1, 'Before scaling', 'After scaling')
```

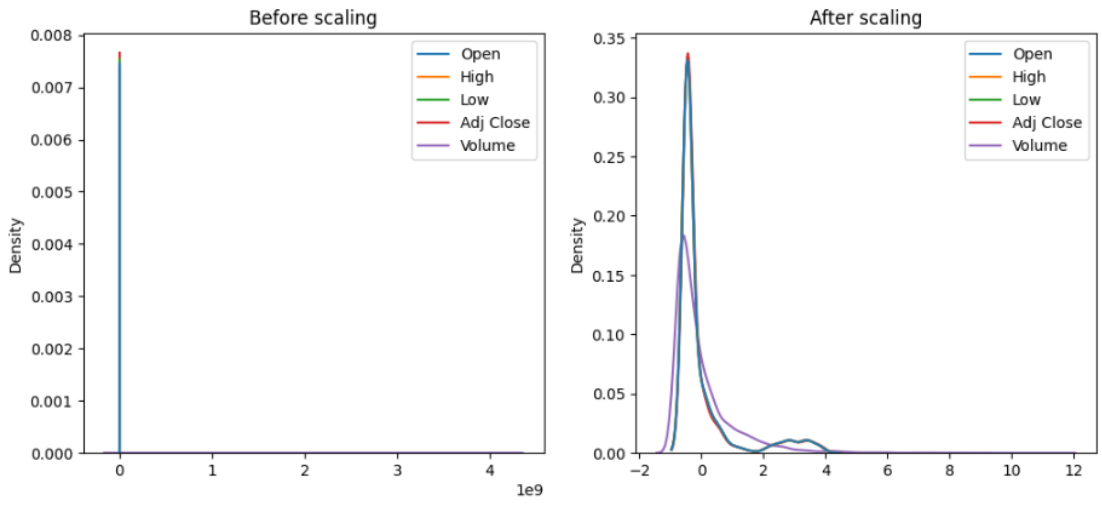

Метод MinMaxScaler

Метод MinMaxScaler

```
scaler2 = MinMaxScaler()
scaled_X_2 = arr_df(scaler2.fit_transform(X_train))
data_visualize(X_train.columns, X_train, scaled_X_2, 'Before scaling', 'After scaling')
```

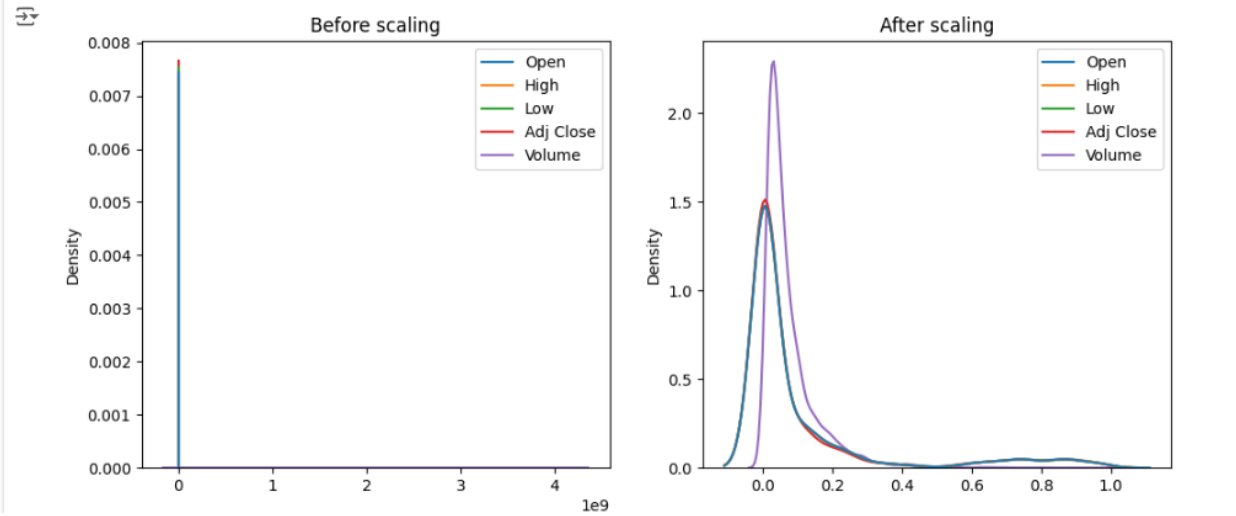

Метод RobusterScaler

Метод RobustScaler

+ 代码 + 文本

```
scaler3 = RobustScaler()
scaled_X_3 = arr_df(scaler3.fit_transform(X_train))
data_visualize(X_train.columns, X_train, scaled_X_3, 'Before scaling', 'After scaling')
```

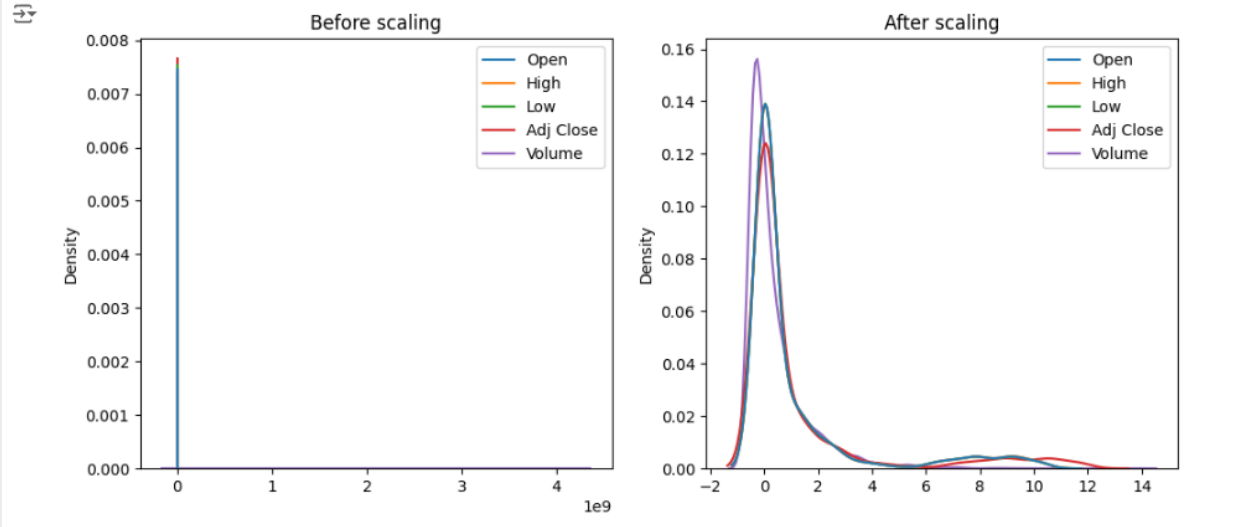

3.2 Обработка выбросов для числовых признаков(удаление выбросов)

```
from enum import Enum
class OutlierBoundaryType(Enum):
    SIGMA = 1
def get_outlier_boundaries(df, col, outlier_boundary_type: OutlierBoundaryType):
    if outlier_boundary_type == OutlierBoundaryType.SIGMA:
        K1 = 3
        lower_boundary = df[col].mean() - (K1 * df[col].std())
        upper_boundary = df[col].mean() + (K1 * df[col].std())

    else:
        raise NameError('Unknown Outlier Boundary Type')

    return lower_boundary, upper_boundary
x_col_list = ['Volume']
data=X_train
for col in x_col_list:
    for obt in OutlierBoundaryType:
        lower_boundary, upper_boundary = get_outlier_boundaries(data, col, obt)
        # Флаги для удаления выбросов
        outliers_temp = np.where(data[col] > upper_boundary, True,
                                 np.where(data[col] < lower_boundary, True, False))
        # Удаление данных на основе флага
        data_trimmed = data.loc[~(outliers_temp), ]
        title = 'Поле-{}, метод-{}, строк-{}'.format(col, obt, data_trimmed.shape[0])
        plot_for_analys(data_trimmed, col, title)
```

```
plt.subplot(1, 2, 1)
```

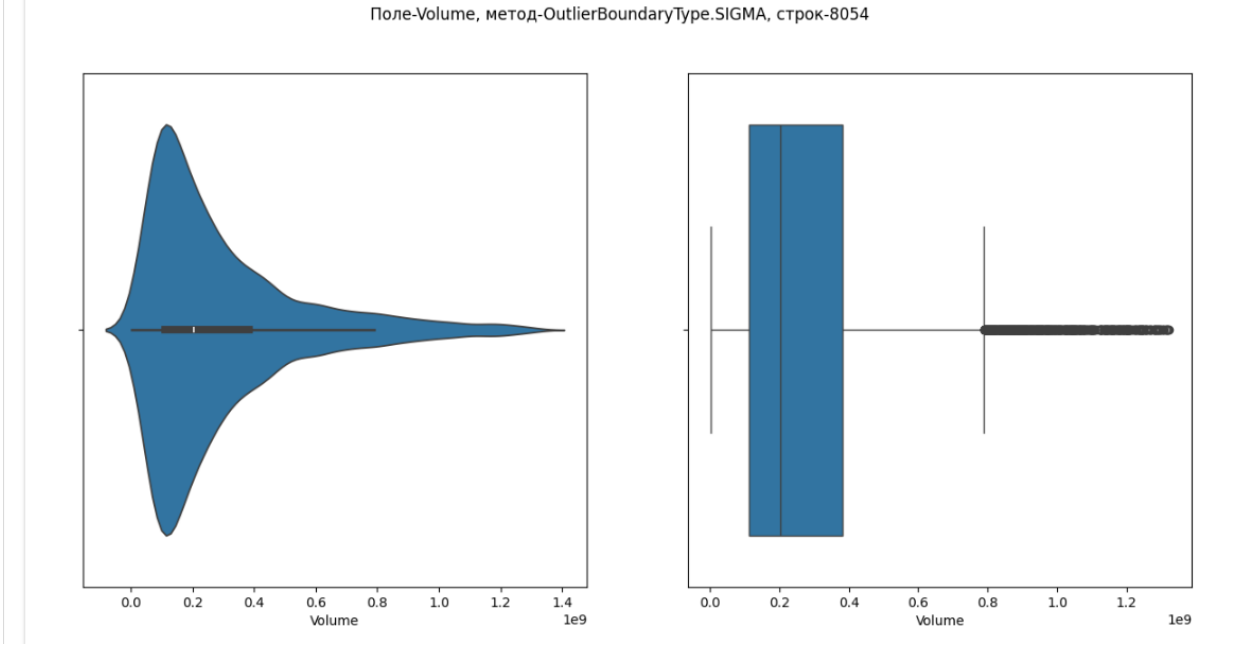

3.3 Отбор признаков

Метод из группы методов фильтрации- Variance Thresholding

```
# 设置方差阈值
threshold = 3000

# 初始化VarianceThreshold对象，并指定阈值
selector = VarianceThreshold(threshold)
selected_features = selector.fit_transform(df)
selected_column_indices = selector.get_support(indices=True)

# 获取保留下来的特征列名称
selected_columns = df.columns[selected_column_indices]

# 打印保留下来的特征列
print("Selected Features:")
print(selected_columns)
```

```
Selected Features:
Index(['Volume'], dtype='object')
```

```
[35] data=df.drop(['Volume'],axis=1)
data
```

	Open	High	Low	Close	Adj Close
0	0.128348	0.128906	0.128348	0.128348	0.099058
1	0.122210	0.122210	0.121652	0.121652	0.093890
2	0.113281	0.113281	0.112723	0.112723	0.086999
3	0.115513	0.116071	0.115513	0.115513	0.089152
4	0.118862	0.119420	0.118862	0.118862	0.091737
...	...	...	...	...	...
10949	189.330002	191.919998	189.009995	191.039993	191.039993
10950	191.089996	192.729996	190.919998	192.350006	192.350006
10951	192.270004	192.820007	190.270004	190.899994	190.899994
10952	190.979996	191.000000	186.630005	186.880005	186.880005
10953	188.820007	190.580002	188.039993	189.979996	189.979996

10954 rows × 5 columns

Метод из группы методов обертывания- Recursive Feature Elimination，RFE

```
#Recursive Feature Elimination，RFE
from sklearn.feature_selection import RFE
from sklearn.linear_model import LinearRegression
import pandas as pd
# 将特征列和目标列分开
X = df.drop('Adj Close', axis=1)
y = df['Adj Close']

# 初始化线性回归模型
model = LinearRegression()

# 初始化RFE对象，指定要保留的特征数量
rfe = RFE(estimator=model, n_features_to_select=3)
selected_features = rfe.fit_transform(X, y)
selected_column_indices = rfe.get_support(indices=True)

# 获取保留下来的特征列名称
selected_columns = X.columns[selected_column_indices]
print("Selected Features:")
print(selected_columns)
```

```
Selected Features:
Index(['Open', 'Low', 'Close'], dtype='object')
```

```
data=df.drop(['Open', 'Low', 'Close'],axis=1)
data
```

	High	Adj Close	Volume
0	0.128906	0.099058	469033600
1	0.122210	0.093890	175884800
2	0.113281	0.086999	105728000
3	0.116071	0.089152	86441600
4	0.119420	0.091737	73449600
...	...	...	...
10949	191.919998	191.039993	44361300
10950	192.729996	192.350006	42309400
10951	192.820007	190.899994	34648500
10952	191.000000	186.880005	51005900
10953	190.580002	189.979996	36294600

10954 rows × 3 columns

后续步骤: 查看推荐的图表

Метод из группы методов вложений

Метод из группы методов вложений

```
[45] from sklearn.linear_model import Lasso
     dataset = pd.read_csv('/content/Apple Dataset.csv')
     dataset.head()
     X=dataset.drop('Date',axis=1)
     y=dataset['Open']
     X_train,X_test,y_train,y_test=train_test_split(X,y)
     X_train=X_train.drop(['Close'],axis=1)
     X_test=X_test.drop(['Close'],axis=1)
     # Используем L1-регуляризацию
     e_ls1 = Lasso(random_state=1)
     e_ls1.fit(X_train, y_train)
     # Коэффициенты регрессии
     list(zip(X_train.columns, e_ls1.coef_))
```

```
[('Open', 0.9994610287218619),
 ('High', 1.0474075642889315e-05),
 ('Low', 0.0),
 ('Adj Close', 0.0),
 ('Volume', -1.8052049707562595e-11)]
```

```
from sklearn.feature_selection import SelectFromModel
sel_e_ls1 = SelectFromModel(e_ls1)
sel_e_ls1.fit(X_train, y_train)
list(zip(X_train.columns, sel_e_ls1.get_support()))
```

```
[('Open', True),
 ('High', True),
 ('Low', False),
 ('Adj Close', False),
 ('Volume', False)]
```

Список литературы

[1] Гапанюк Ю. Е. Лабораторная работа «Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей» [Электронный ресурс] // GitHub. — 2019. — Режим доступа: https://github.com/ugapanyuk/ml_course/wiki/LAB_KNN (дата обращения: 05.04.2019).
[2] Team The IPython Development. IPython 7.3.0 Documentation [Electronic resource] // Read the Docs. — 2019. — Access mode: https://ipython.readthedocs.io/en/stable/ (online; accessed: 20.02.2019).

[3] Waskom M. seaborn 0.9.0 documentation [Electronic resource] // PyData. — 2018. —

Access mode: https://seaborn.pydata.org/ (online; accessed: 20.02.2019).
[4] pandas 0.24.1 documentation [Electronic resource] // PyData. — 2019. — Access mode: http://pandas.pydata.org/pandas-docs/stable/ (online; accessed: 20.02.2019).
[5] dronio. Solar Radiation Prediction [Electronic resource] // Kaggle. — 2017. — Access mode: https://www.kaggle.com/dronio/SolarEnergy (online; accessed: 18.02.2019).
[6] Chrétien M. Convert datetime.time to seconds [Electronic resource] // Stack Overflow. — 2017. — Access mode: https://stackoverflow.com/a/44823381 (online; accessed: 20.02.2019).
[7] scikit-learn 0.20.3 documentation [Electronic resource]. — 2019. — Access mode: https://scikit-learn.org/ (online; accessed: 05.04.2019).